

第 02 讲：统计语言模型

DATA130030.01, 自然语言处理 (阅读时长约 60 分钟)

日期：2025 年 9 月 17 日

主讲人：周宝健

单位：复旦大学数据科学学院

译注 (勘误)：原文开头有一处孤立的 $\$ \times \$$ ，系排版残留，已删除。原文 bigram 推导中将 v_0 误称为“EOS 起始标记”，应为 BOS，译文已更正。unigram 推导中对 λ 求偏导的求和上限原文写为 $|\mathcal{V}|$ ，应为 $|\mathcal{V}| + 1$ (含 EOS)，译文已更正。

本讲介绍 N -gram 语言模型。我们将定义 N -gram 语言模型，并说明如何使用最大似然估计 (MLE) 来学习模型参数；接着讨论处理零概率问题的技术 (平滑)，并定义困惑度 (perplexity)。

符号说明

经过分词后，一个句子表示为 $[w_1, w_2, \dots, w_t]$ ，记作 $s = w_{1:t}$ 。例如，句子 “the cat saw the dog” 对应 $s = w_{1:5} = [the, cat, saw, the, dog]$ 。设 $P(X)$ 表示离散随机变量 X 的概率分布，用 w_i 表示句子第 i 个位置的随机变量 X_i ，即 $P(X_i = w_i) \equiv P(w_i)$ 。设 X_{i+1} 表示选择 w_{i+1} ， X_i 表示在 w_{i+1} 之前出现的 w_i ，则 $P(X_i, X_{i+1})$ 为 $w_i w_{i+1}$ 的联合概率，记作 $P(X_i = w_i, X_{i+1} = w_{i+1}) \equiv P(w_{i:i+1})$ 。我们定义词表 $\mathcal{V} = \{v_1, v_2, \dots, v_{|\mathcal{V}|}\}$ ，以及两个特殊符号 $v_0 = \text{BOS}$ (句首) 和 $v_{|\mathcal{V}|+1} = \text{EOS}$ (句尾)。

动机

假设你正在做一个语音识别任务，需要设计一个语音识别器。给定一段声学信号，识别器产生两个候选句子： $s_1 = \text{“It’s hard to recognize speech”}$ (语音识别很难) 和 $s_2 = \text{“It’s hard to wreck a nice beach”}$ (毁掉一片好海滩很难)。如果模型足够好，它应使 $P(s_1) > P(s_2)$ ，因为两者的声学信号非常相似，但 s_1 在日常语言中更为合理。因此，语音识别器需要能够为不同的句子序列赋予概率，以比较 s_1 和 s_2 在现实中出现的可能性。**语言建模的任务就是为句子赋予概率**，即我们希望学到一个分布 P ，使得 $P(s_1) > P(s_2)$ 。

我们的任务：目标是在给定某语言词表 $\mathcal{V}$ 下的**训练语料库** (一组句子) 上学习一个语言模型。利用训练语料库学习模型后，使用**验证语料库**调整模型超参数，最后用**测试语料库**评估训练好的语言模型的性能。

统计语言模型与 N -gram

统计语言模型定义了给定词表 $\mathcal{V}$ 上句子的概率分布。英语语言模型词表可能是 $\mathcal{V} = \{the, dog, laughs, saw, \dots\}$ ，其中 $\mathcal{V}$ 是有限集。语言中的**句子**是词的序列

$$s = w_1 w_2 \dots w_t \equiv w_{1:t},$$

其中整数 $t \geq 1$ 不固定， $w_i \in \mathcal{V}$ ($i \in \{1, \dots, t-1\}$)，并假设 $w_t = \text{EOS}$ 是不在 $\mathcal{V}$ 中的特殊符号。定义 $\mathcal{V}^\dagger$ 为词表 $\mathcal{V}$ 上所有句子的集合，它是无限集 (句子长度任意)。例如：

$$\mathcal{V}^\dagger = \{\text{the dog barks EOS, the EOS, cat cat cat EOS, EOS, } \dots\}.$$

语言模型计算 $w_{1:t}$ 的概率 $p(w_{1:t})$ ，其正式定义如下：

定义 (语言模型, LM)

给定有限词表 $\mathcal{V}$ ，对任意 $t \geq 1$ ，长度为 t 的句子是序列 $w_{1:t}$ ，其中 $w_i \in \mathcal{V}$ ($i = 1, \dots, t-1$)，

$w_t = \text{EOS}$ 。设 $\mathcal{V}^\dagger$ 为所有此类句子的集合。**语言模型**是定义在 $\mathcal{V}^\dagger$ 上的概率分布函数 $p(w_{1:t})$ ，满足：

- 对任意 $w_{1:t} \in \mathcal{V}^\dagger$, $p(w_{1:t}) \geq 0$;
- $\sum_{w_{1:t} \in \mathcal{V}^\dagger} p(w_{1:t}) = 1$ 。

由此, $p(w_{1:t})$ 是定义在 $\mathcal{V}^\dagger$ 上的概率分布。语言模型使我们能够**理解** (通过 p 比较任意两个句子的概率) 和**生成** (用分布 p 生成句子)。利用链式法则, 可将其分解为条件概率之积:

$$p(w_{1:t}) = \prod_{i=1}^t p(w_i | w_{1:i-1}),$$

其中 $p(w_1 | w_{1:0} = \text{BOS}) = p(w_1)$, $w_{1:i-1}$ 称为 w_i 的**历史**。精确计算 $p(w_{1:t})$ 通常极为困难。例如, 仅对 5 个词的句子 $p(w_{1:5})$, 在 $|\mathcal{V}| = 10^4$ 时就需要约 10^{20} 个参数。目前所有语言模型本质上都是对 $p(w_{1:t})$ 的**估计**, 有三大类:

1. **统计语言模型**: 使用统计方法, 基于词序列的概率预测下一个词, 即 N -gram 模型。
2. **神经语言模型**: 基于神经网络, 包括两层神经网络 (word2vec) 和 RNN (如 LSTM、GRU) 等架构。
3. **大语言模型 (LLM)**: 使用自注意力机制 (Transformer) 的神经网络模型, 如 BERT 和 GPT 系列。

为何需要 $w_t = \text{EOS}$? 句子长度 t 本身是随机变量。最常见的处理方式是令最后一个词 w_t 始终等于特殊符号 EOS, 且该符号只能出现在序列末尾。

近似 $p(w_{1:t})$ 是构建实用语言模型的关键。在**一阶马尔可夫假设**下, $p(w_{1:t}) = \prod_{i=1}^t P(X_i = w_i | X_{i-1} = w_{i-1})$ 。类似地, 在**二阶马尔可夫假设**下:

$$p(w_{1:t}) = \prod_{i=1}^t P(X_i = w_i | X_{i-2} = w_{i-2}, X_{i-1} = w_{i-1}),$$

生成句子的步骤如下:

- **步骤 1**: 初始化 $i = 1$, 令 $x_0 = x_{-1} = \text{BOS}$;
- **步骤 2**: 从分布 $p(X_i = x_i | X_{i-2:i-1} = x_{i-2:i-1})$ 中采样 x_i ;
- **步骤 3**: 若 $x_i = \text{EOS}$, 则返回 $x_{1:i}$; 否则令 $i = i + 1$, 返回步骤 2。

N -gram 模型的正式定义如下:

定义 (N -gram 语言模型)

给定有限词表 $\mathcal{V}$, N -gram 语言模型在 $(N - 1)$ 阶马尔可夫假设下计算句子 $w_{1:t}$ 的概率:

$$p(w_{1:t}) = \prod_{i=1}^t q(w_i | w_{i-N+1:i-1}),$$

其中 $q(x_N | x_{1:N-1})$ 是 N -gram $x_{1:N}$ 的条件概率分布, $x_i \in \mathcal{V} \cup \{\text{BOS}\}$ ($i = 1, \dots, N - 1$), $x_N \in \mathcal{V} \cup \{\text{EOS}\}$ 。默认规定 $i \leq 0$ 时 $w_i = \text{BOS}$ 。

具体而言:

- $N = 1$: **一元模型 (Unigram)**, $p(w_{1:t}) = \prod_{i=1}^t q(w_i)$;
- $N = 2$: **二元模型 (Bigram)**, $p(w_{1:t}) = \prod_{i=1}^t q(w_i | w_{i-1})$;
- $N = 3$: **三元模型 (Trigram)**, $p(w_{1:t}) = \prod_{i=1}^t q(w_i | w_{i-2:i-1})$ 。

模型参数约有 $|\mathcal{V}|^N$ 个。以 $|\mathcal{V}| = 10,000$ 、 $N = 3$ 为例, 参数数量约 10^{12} , 数量极为庞大。

从训练语料库通过最大似然估计学习 $q(x_N \mid x_{1:N-1})$

训练数据集为：

$$\mathcal{D}_{\text{tr}} = \{s_1, s_2, \dots, s_T\} \equiv s_{1:T}, \quad s_i = w_{1:t_i}^{(i)} \in \mathcal{V}^\dagger.$$

设模型由参数向量 $\theta = [\theta_1, \theta_2, \dots, \theta_d]^\top$ 刻画。**最大似然估计 (MLE)** 的目标是找到使观测数据联合概率最大的参数：

$$\hat{\theta} \in \arg \max_{\theta \in \Theta} \{\mathcal{L}_T(\theta; \mathcal{D}_{\text{tr}}) := P(s_{1:T}; \theta)\}.$$

一元模型的 MLE

在一元模型假设下：

$$P(s_{1:T}) = \prod_{i=1}^{|\mathcal{V}|+1} \theta_i^{C(v_i)},$$

其中 $C(v_i)$ 为 v_i 在训练语料中出现的次数，参数向量 $\theta = [\theta_1, \dots, \theta_{|\mathcal{V}|}, \theta_{\text{EOS}}]^\top$ ，约束为 $\sum_{i=1}^{|\mathcal{V}|+1} \theta_i = 1$ 。

对数似然为：

$$\arg \max_{\sum_j \theta_j = 1} \sum_{i=1}^{|\mathcal{V}|+1} C(v_i) \log \theta_i.$$

引入拉格朗日乘子 λ ，构造拉格朗日函数：

$$G(\theta, \lambda) = \sum_{i=1}^{|\mathcal{V}|+1} C(v_i) \log \theta_i - \lambda \left(\sum_{i=1}^{|\mathcal{V}|+1} \theta_i - 1 \right).$$

令偏导为零（勘误：原文求和上限为 $|\mathcal{V}|$ ，应为 $|\mathcal{V}| + 1$ ）：

$$\frac{\partial G}{\partial \theta_i} = \frac{C(v_i)}{\theta_i} - \lambda = 0, \quad \frac{\partial G}{\partial \lambda} = \sum_{i=1}^{|\mathcal{V}|+1} \theta_i - 1 = 0.$$

解得：

$$\theta_i^* = \frac{C(v_i)}{\sum_{i=1}^T |s_i|}.$$

即一元模型的 MLE 参数就是**频率估计**。

二元模型的 MLE

对于二元模型, 令 $\theta_{i,j+1} := q(v_{j+1} | v_i)$, 约束为对所有 i : $\sum_{j=0}^{|\mathcal{V}|} \theta_{i,j+1} = 1$.

对数似然为:

$$\log P(s_{1:T}; \Theta) = \sum_{i=0}^{|\mathcal{V}|} \sum_{j=0}^{|\mathcal{V}|} C(v_i, v_{j+1}) \log q(v_{j+1} | v_i).$$

类似地引入拉格朗日乘子 λ_i , 令梯度为零, 解得:

$$\theta_{i,j+1}^* = q(v_{j+1} | v_i) = \frac{C(v_i, v_{j+1})}{\sum_{j=0}^{|\mathcal{V}|} C(v_i, v_{j+1})}.$$

对三元模型及更高阶, MLE 估计为:

$$q(x_N | x_{1:N-1}) = \frac{C(x_{1:N})}{C(x_{1:N-1})}.$$

N -gram 语言模型的平滑

N -gram 模型通常存在数据稀疏问题。例如, 在 3800 万词的新闻语料上观察所有三元组后, 同来源新文章中仍有约三分之一的三元组是全新未见的。对未见 N -gram 直接用 MLE 会导致零概率, 因此需要平滑技术——从高频事件中“削减”一些概率质量, 分配给未见事件。

加法平滑 (Additive Smoothing)

对每个 N -gram 计数加上一个小量 δ (通常 $0 < \delta \leq 1$):

$$q_{\text{Add}}(x_N | x_{1:N-1}) = \frac{\delta + C(x_{1:N})}{\delta(|\mathcal{V}| + 1) + \sum_{x_N \in \mathcal{V} \cup \{\text{EOS}\}} C(x_{1:N})}.$$

最简单的情形是 $\delta = 1$ (加一平滑)。

线性插值 (Linear Interpolation)

以三元模型为例, 将三元、二元、一元估计加权混合:

$$q_{\text{Int}}(x_3 | x_{1:2}) = \lambda_1 \cdot q_{\text{ML}}(x_3) + \lambda_2 \cdot q_{\text{ML}}(x_3 | x_2) + \lambda_3 \cdot q_{\text{ML}}(x_3 | x_{1:2}),$$

其中 $\sum_{i=1}^3 \lambda_i = 1$, 各 λ_i 从验证集学习。一种简化的“分桶”方法 (Bucketing) 定义为:

$$\lambda_1 = \frac{C(x_{1:2})}{C(x_{1:2}) + \gamma}, \quad \lambda_2 = (1 - \lambda_1) \cdot \frac{C(x_2)}{C(x_2) + \gamma}, \quad \lambda_3 = 1 - \lambda_1 - \lambda_2,$$

其中 $\gamma > 0$ 为唯一超参数。可验证各 λ_i 为正且和为 1。

Katz 回退平滑 (Katz Back-off)

对二元模型, 对任意 x_1 定义:

$$\mathcal{A}(x_1) = \{x_2 : C(x_1 x_2) > 0\}, \quad \mathcal{B}(x_1) = \{x_2 : C(x_1 x_2) = 0\}.$$

估计为:

$$q_{\text{Katz}}(x_2 | x_1) = \begin{cases} \frac{C^*(x_1, x_2)}{C(x_1)} & \text{若 } x_2 \in \mathcal{A}(x_1) \\ \alpha(x_1) \cdot \frac{q_{\text{ML}}(x_2)}{\sum_{x_2 \in \mathcal{B}(x_1)} q_{\text{ML}}(x_2)} & \text{若 } x_2 \in \mathcal{B}(x_1) \end{cases}$$

其中折扣计数 $C^*(x_1, x_2) = C(x_1, x_2) - \beta$, 典型取值 $\beta = 0.5$ 。对三元模型, 类似地定义 $\mathcal{A}(u, v)$ 和 $\mathcal{B}(u, v)$:

$$q_{\text{Katz}}(w | u, v) = \begin{cases} \frac{C^*(u, v, w)}{C(u, v)} & \text{若 } w \in \mathcal{A}(u, v) \\ \alpha(u, v) \cdot \frac{q_{\text{Katz}}(w | v)}{\sum_{w \in \mathcal{B}(u, v)} q_{\text{Katz}}(w | v)} & \text{若 } w \in \mathcal{B}(u, v) \end{cases}$$

其中 $\alpha(u, v) = 1 - \sum_{w \in \mathcal{A}(u, v)} \frac{C^*(u, v, w)}{C(u, v)}$ 。

Kneser-Ney 平滑 (Kneser-Ney Smoothing)

给定折扣参数 $\delta \in [0, 1]$, 二元 KN 平滑为:

$$q_{\text{KN}}(x_2 | x_1) = \frac{\max\{C(x_1 x_2) - \delta, 0\}}{\sum_{x \in \mathcal{V} \cup \{\text{EOS}\}} C(x_1 x)} + \lambda_{x_1} \cdot q_{\text{KN}}(x_2),$$

其中一元概率衡量词 x_2 出现在新上下文中的可能性:

$$q_{\text{KN}}(x_2) = \frac{|\{x : C(x x_2) > 0\}|}{|\{(x_1, x_2) : C(x_1 x_2) > 0\}|},$$

参数 λ_{x_1} 为:

$$\lambda_{x_1} = \frac{\delta \cdot |\{w : C(x_1 w) > 0\}|}{\sum_v C(x_1 v)}.$$

推广到 N -gram:

$$q_{\text{KN}}(x_N | x_{1:N-1}) = \frac{\max\{C(x_{1:N}) - \delta, 0\}}{\sum_{x \in \mathcal{V} \cup \{\text{EOS}\}} C(x_{1:N-1} x)} + \lambda_{x_{1:N-1}} \cdot q_{\text{KN}}(x_N | x_{2:N-1}),$$

其中:

$$\lambda_{x_{1:N-1}} = \frac{\delta \cdot |\{x : C(x_{1:N-1} x) > 0\}|}{\sum_{x \in \mathcal{V} \cup \{\text{EOS}\}} C(x_{1:N-1} x)}.$$

改进版 Kneser-Ney 平滑已在 [kenlm](#) 中实现。

愚蠢回退 (Stupid Back-off)

不带折扣的回退 (非真正的概率):

$$S(x_N | x_{1:N-1}) = \begin{cases} \frac{C(x_{1:N})}{C(x_{1:N-1})} & \text{若 } C(x_{1:N}) > 0 \\ 0.4 \cdot S(x_N | x_{2:N-1}) & \text{否则} \end{cases}$$

$$S(x_N) = \frac{C(x_N)}{T},$$

其中 T 为训练语料的总大小。

用困惑度评估 N -gram

设测试数据为句子 $s_1, s_2, \dots, s_m$, 一个好的模型应对这些真实句子赋予较高概率。总体质量可用:

$$\prod_{i=1}^m p(s_i)$$

来衡量。设 $M = \sum_{i=1}^m t_i$ 为测试语料的总词数, **平均对数概率**定义为:

$$\frac{1}{\sum_{i=1}^m |s_i|} \log_2 \prod_{i=1}^m p(s_i) = \frac{1}{\sum_{i=1}^m |s_i|} \sum_{i=1}^m \log_2 p(s_i).$$

困惑度 (Perplexity) 定义为:

$$\text{PPL}(s_{1:m}) := 2^{-l}, \quad \text{其中 } l = \frac{1}{\sum_{i=1}^m |s_i|} \sum_{i=1}^m \log_2 p(s_i).$$

困惑度是正数, **值越小, 语言模型对未见数据的建模能力越强**。其直觉含义为: “如果在每一步按照语言模型的概率分布随机采样词, 平均需要采样多少次才能得到正确的词?” (Neubig, 2017, 第 9 页)。

示例: 若一元模型对所有词赋予相同概率, 则 $\text{PPL}(s_{1:m}) = |\mathcal{V}|$ ——平均需要从全部词表中选择。若 $|\mathcal{V}| = 1,000,000$ 且一个好的语言模型的困惑度为 30, 则平均只需选约 30 个词。

熵与交叉熵

困惑度本质上衡量语言模型的**熵**。给定离散随机变量 X , **熵**定义为:

$$H(p) \triangleq - \sum_{i=1}^n p(x_i) \log p(x_i).$$

分布 q 相对于分布 p 的**交叉熵**定义为:

$$H(p, q) = - \sum_{x_i \in \mathcal{X}} p(x_i) \log q(x_i).$$

在语言模型中, p 为真实分布, q 为从训练语料估计的分布。由于真实分布未知, 我们无法直接计算 $H(p)$ 或 $H(p, q)$ 。但可以利用:

$$H(p, q) = H(p) + \underbrace{\sum_{x_i \in \mathcal{X}} p(x_i) (\log p(x_i) - \log q(x_i))}_{D_{\text{KL}}(p \| q) \geq 0} \geq H(p).$$

因此 $H(p, q)$ 是 $H(p)$ 的上界, q 越接近 p , $H(p, q)$ 越接近 $H(p)$ (等号当且仅当 $p = q$ 时成立)。

由 **Shannon-McMillan-Breiman 定理** (Jurafsky, 2022, 公式 3.49):

$$H(p) \leq H(p, q) = \lim_{n \rightarrow \infty} -\frac{1}{n} \log q(w_{1:n}) \approx H(s_{1:m}) \triangleq -\frac{1}{|s_{1:m}|} \log p(s_{1:m}).$$

困惑度正是该近似量 $H(s_{1:m})$ 的指数形式:

$$\text{PPL}(s_{1:m}) = 2^{-\frac{1}{|s_{1:m}|} \log_2 p(s_{1:m})} = 2^{H(s_{1:m})}.$$

采用指数形式没有特别原因, 但它使数值差异更为显著, 比 $H(W)$ 对模型性能更为敏感。

困惑度的优势: 1. 比熵值更直观易记 (如 100–200 的困惑度范围, 比 6.64–7.64 比特的熵值更具可解释性); 2. 10% 的困惑度改善比 2% 的熵减小更具感知显著性; 3. 可直接用留出集或测试数据计算, 困惑度越低说明模型越接近生成观测数据的“真实”模型。

N -gram 模型的核心组件曾被用于第一代谷歌翻译 (Brants et al., 2007)。然而, 作为纯统计语言模型, 它已先后被基于 RNN 的模型和大语言模型 (LLM) 所取代。

参考文献

- https://cs229.stanford.edu/lectures-spring2023/cs229-probability_review.pdf
- https://cs229.stanford.edu/notes2022fall/main_notes.pdf
- <https://anoopsarkar.github.io/nlp-class/assets/slides/prob.pdf>
- <https://www.cs.columbia.edu/~mccollins/courses/nlp2011/notes/lm.pdf>
- <https://pages.cs.wisc.edu/~jerryzhu/cs838/LM.pdf>
- <https://www3.nd.edu/~dchiang/teaching/nlp/2021/notes/chapter2v2.pdf>
- <https://www.fit.vut.cz/study/phd-thesis-file/283/283.pdf>

附录

Jensen 不等式: 对凹函数 $\varphi: \mathbb{R} \rightarrow \mathbb{R}$ 及正权 a_i :

$$\varphi\left(\sum_{i=1}^n \frac{x_i}{n}\right) \geq \frac{1}{n} \sum_{i=1}^n \varphi(x_i) \quad (\text{当 } a_i = 1).$$

定理 (最大熵)

对随机变量 X 及其概率分布 p , 当 p 为均匀分布时, X 的熵最大。

证明:

令 $\varphi(y) = -y \log y$ (规定 $\varphi(0) = 0$), 设 X 有 n 个可能取值 $x_1, \dots, x_n$, 概率为 $p(x_1), \dots, p(x_n)$ 。由于 $\varphi(y)$ 在 $[0, 1]$ 上为凹函数, 由 Jensen 不等式:

$$\begin{aligned} n \cdot \varphi\left(\sum_{i=1}^n \frac{y_i}{n}\right) &\geq \sum_{i=1}^n \varphi(y_i) \\ n \cdot \left(-\frac{1}{n}\right) \log\left(\frac{1}{n}\right) &\geq -\sum_{i=1}^n p(x_i) \log p(x_i) := H(p), \end{aligned}$$

即 $\log(n) \geq H(p)$ 。上界在 $p(x_i) = 1/n$ (均匀分布) 时取到, 证毕。

更多内容见 Conrad (2004)。