

第 02 讲：统计语言模型

DATA130030.01, 自然语言处理 (阅读时长约 60 分钟)

日期：2025 年 9 月 17 日

主讲人：周宝健

单位：复旦大学数据科学学院

译注 (勘误)：原文开头有一处孤立的 $\$ \times \$$ ，系排版残留，已删除。原文 bigram 推导中将 v_0 误称为“EOS 起始标记”，应为 BOS，译文已更正。unigram 推导中对 λ 求偏导的求和上限原文写为 $|\mathcal{V}|$ ，应为 $|\mathcal{V}| + 1$ (含 EOS)，译文已更正。

本讲介绍 N -gram 语言模型。我们将定义 N -gram 语言模型，并说明如何使用最大似然估计 (MLE) 来学习模型参数；接着讨论处理零概率问题的技术 (平滑)，并定义困惑度 (perplexity)。

符号说明

经过分词后，一个句子表示为 $[w_1, w_2, \dots, w_t]$ ，记作 $s = w_{1:t}$ 。例如，句子 “the cat saw the dog” 对应 $s = w_{1:5} = [the, cat, saw, the, dog]$ 。设 $P(X)$ 表示离散随机变量 X 的概率分布，用 w_i 表示句子第 i 个位置的随机变量 X_i ，即 $P(X_i = w_i) \equiv P(w_i)$ 。设 X_{i+1} 表示选择 w_{i+1} ， X_i 表示在 w_{i+1} 之前出现的 w_i ，则 $P(X_i, X_{i+1})$ 为 $w_i w_{i+1}$ 的联合概率，记作 $P(X_i = w_i, X_{i+1} = w_{i+1}) \equiv P(w_{i:i+1})$ 。我们定义词表 $\mathcal{V} = \{v_1, v_2, \dots, v_{|\mathcal{V}|}\}$ ，以及两个特殊符号 $v_0 = \text{BOS}$ (句首) 和 $v_{|\mathcal{V}|+1} = \text{EOS}$ (句尾)。

动机

假设你正在做一个语音识别任务，需要设计一个语音识别器。给定一段声学信号，识别器产生两个候选句子： $s_1 = \text{“It’s hard to recognize speech”}$ (语音识别很难) 和 $s_2 = \text{“It’s hard to wreck a nice beach”}$ (毁掉一片好海滩很难)。如果模型足够好，它应使 $P(s_1) > P(s_2)$ ，因为两者的声学信号非常相似，但 s_1 在日常语言中更为合理。因此，语音识别器需要能够为不同的句子序列赋予概率，以比较 s_1 和 s_2 在现实中出现的可能性。**语言建模的任务就是为句子赋予概率**，即我们希望学到一个分布 P ，使得 $P(s_1) > P(s_2)$ 。

我们的任务：目标是在给定某语言词表 $\mathcal{V}$ 下的**训练语料库** (一组句子) 上学习一个语言模型。利用训练语料库学习模型后，使用**验证语料库**调整模型超参数，最后用**测试语料库**评估训练好的语言模型的性能。

统计语言模型与 N -gram

统计语言模型定义了给定词表 $\mathcal{V}$ 上句子的概率分布。英语语言模型的词表可能是 $\mathcal{V} = \{the, dog, laughs, saw, \dots\}$ ，其中 $\mathcal{V}$ 是有限集。语言中的**句子**是词的序列

$$s = w_1 w_2 \dots w_t \equiv w_{1:t},$$

其中整数 $t \geq 1$ 不固定， $w_i \in \mathcal{V}$ ($i \in \{1, \dots, t-1\}$)，并假设 $w_t = \text{EOS}$ 是不在 $\mathcal{V}$ 中的特殊符号。定义 $\mathcal{V}^\dagger$ 为词表 $\mathcal{V}$ 上所有句子的集合，它是无限集 (句子长度任意)。例如：

$$\mathcal{V}^\dagger = \{\text{the dog barks EOS, the EOS, cat cat cat EOS, EOS, } \dots\}.$$

语言模型计算 $w_{1:t}$ 的概率 $p(w_{1:t})$ ，其正式定义如下：

定义 (语言模型, LM)

给定有限词表 $\mathcal{V}$ ，对任意 $t \geq 1$ ，长度为 t 的句子是序列 $w_{1:t}$ ，其中 $w_i \in \mathcal{V}$ ($i = 1, \dots, t-1$)，

$w_t = \text{EOS}$ 。设 $\mathcal{V}^\dagger$ 为所有此类句子的集合。**语言模型**是定义在 $\mathcal{V}^\dagger$ 上的概率分布函数 $p(w_{1:t})$ ，满足：

- 对任意 $w_{1:t} \in \mathcal{V}^\dagger$, $p(w_{1:t}) \geq 0$;
- $\sum_{w_{1:t} \in \mathcal{V}^\dagger} p(w_{1:t}) = 1$ 。

由此, $p(w_{1:t})$ 是定义在 $\mathcal{V}^\dagger$ 上的概率分布。语言模型使我们能够**理解** (通过 p 比较任意两个句子的概率) 和**生成** (用分布 p 生成句子)。利用链式法则, 可将其分解为条件概率之积:

$$p(w_{1:t}) = \prod_{i=1}^t p(w_i | w_{1:i-1}),$$

其中 $p(w_1 | w_{1:0} = \text{BOS}) = p(w_1)$, $w_{1:i-1}$ 称为 w_i 的**历史**。精确计算 $p(w_{1:t})$ 通常极为困难。例如, 仅对 5 个词的句子 $p(w_{1:5})$, 在 $|\mathcal{V}| = 10^4$ 时就需要约 10^{20} 个参数。目前所有语言模型本质上都是对 $p(w_{1:t})$ 的**估计**, 有三大类:

1. **统计语言模型**: 使用统计方法, 基于词序列的概率预测下一个词, 即 N -gram 模型。
2. **神经语言模型**: 基于神经网络, 包括两层神经网络 (word2vec) 和 RNN (如 LSTM、GRU) 等架构。
3. **大语言模型 (LLM)**: 使用自注意力机制 (Transformer) 的神经网络模型, 如 BERT 和 GPT 系列。

为何需要 $w_t = \text{EOS}$? 句子长度 t 本身是随机变量。最常见的处理方式是令最后一个词 w_t 始终等于特殊符号 EOS, 且该符号只能出现在序列末尾。

近似 $p(w_{1:t})$ 是构建实用语言模型的关键。在**一阶马尔可夫假设**下, $p(w_{1:t}) = \prod_{i=1}^t P(X_i = w_i | X_{i-1} = w_{i-1})$ 。类似地, 在**二阶马尔可夫假设**下:

$$p(w_{1:t}) = \prod_{i=1}^t P(X_i = w_i | X_{i-2} = w_{i-2}, X_{i-1} = w_{i-1}),$$

生成句子的步骤如下:

- **步骤 1**: 初始化 $i = 1$, 令 $x_0 = x_{-1} = \text{BOS}$;
- **步骤 2**: 从分布 $p(X_i = x_i | X_{i-2:i-1} = x_{i-2:i-1})$ 中采样 x_i ;
- **步骤 3**: 若 $x_i = \text{EOS}$, 则返回 $x_{1:i}$; 否则令 $i = i + 1$, 返回步骤 2。

N -gram 模型的正式定义如下:

定义 (N -gram 语言模型)

给定有限词表 $\mathcal{V}$, N -gram 语言模型在 $(N - 1)$ 阶马尔可夫假设下计算句子 $w_{1:t}$ 的概率:

$$p(w_{1:t}) = \prod_{i=1}^t q(w_i | w_{i-N+1:i-1}),$$

其中 $q(x_N | x_{1:N-1})$ 是 N -gram $x_{1:N}$ 的条件概率分布, $x_i \in \mathcal{V} \cup \{\text{BOS}\}$ ($i = 1, \dots, N - 1$), $x_N \in \mathcal{V} \cup \{\text{EOS}\}$ 。默认规定 $i \leq 0$ 时 $w_i = \text{BOS}$ 。

具体而言:

- $N = 1$: **一元模型 (Unigram)**, $p(w_{1:t}) = \prod_{i=1}^t q(w_i)$;
- $N = 2$: **二元模型 (Bigram)**, $p(w_{1:t}) = \prod_{i=1}^t q(w_i | w_{i-1})$;
- $N = 3$: **三元模型 (Trigram)**, $p(w_{1:t}) = \prod_{i=1}^t q(w_i | w_{i-2:i-1})$ 。

模型参数约有 $|\mathcal{V}|^N$ 个。以 $|\mathcal{V}| = 10,000$ 、 $N = 3$ 为例, 参数数量约 10^{12} , 数量极为庞大。